

MEMORIA TECNICA

Operacion Picos de Europa

Orquestador clinico Idonia × Recog con cinturon cuantitativo de fidelidad

Reto del Hackaton IABiomed 2026

Universidad de Leon · IABiomed

Caso clinico de referencia: RM de rodilla 1.5T · escenario pivot-shift

Documento: arquitectura, planteamiento, dificultades tecnicas resueltas y herramientas de IA
empleadas

Junio de 2026

1. Resumen ejecutivo

El reto **Operacion Picos de Europa** consiste en orquestar dos APIs reales del sector sanitario español para llevar un estudio de imagen medica desde el informe radiologico tecnico hasta el paciente, de forma comprensible y, sobre todo, **clínicamente fiel**. Las dos piezas son **Idonia** (middleware de imagen DICOM y entrega segura por Magic Link) y **Recog** (NLP medico en español que humaniza el informe).

Nuestra aportacion diferencial no es conectar ambas APIs —eso es el sustrato—, sino interponer entre ellas un **control de calidad cuantitativo** que decide, con criterios medibles, si el informe humanizado es lo bastante fiel como para entregarselo al paciente. Lo llamamos **el cinturon**: un gate real de cuatro capas que, si falla, **no reinyecta** el informe humanizado en Idonia. No es decorativo: protege al paciente frente a humanizaciones que atenuen la gravedad de un hallazgo.

La arquitectura completa cabe en una frase:

Recog humaniza → el cinturon valida (4 capas) → Idonia almacena y entrega por Magic Link.

El proyecto esta operativo de extremo a extremo en modo *offline* (sin red ni credenciales): el demo procesa un informe fiel y otro con atenuaciones clinicas sembradas, y bloquea correctamente el segundo. La suite automatizada (32 pruebas) pasa en verde. Frente a las APIs reales, la humanizacion de Recog quedo verificada contra produccion; el modo *live* de Idonia esta implementado a partir de su Swagger y pendiente de validacion end-to-end con su equipo de soporte.

2. El reto y la logica del planteamiento

Humanizar un informe radiologico no es un problema de estilo, es un problema de seguridad clinica. Una traduccion a lenguaje de paciente que convierta «*rotura completa del ligamento cruzado anterior*» en «*el ligamento esta algo afectado*» es legible, pero es peligrosa: cambia el pronostico y el plan terapeutico. Por eso nuestro planteamiento parte de una distincion que vertebra todo el sistema:

- **Simplificacion apropiada** — se elimina la jerga, pero la gravedad clinica se preserva. Es el *objetivo* de la humanizacion (p.ej. «condromalacia grado II» → «desgaste del cartilago»).
- **Atenuacion de gravedad** — se minimiza la gravedad de forma que un medico o el paciente podrian tomar una decision incorrecta. Es el *riesgo* que hay que detectar y bloquear (p.ej. «rotura completa» → «pequena fisura que se cura sola»).

El criterio operativo que aplicamos en todo el cinturon es: *¿un medico que leyera el informe humanizado tomaria la misma decision terapeutica que con el original?* Si la respuesta es si, la simplificacion es legitima; si es no, hay riesgo clinico. Construir un sistema que sepa discriminar entre ambos casos —y no aplicar una regla ciega— es el nucleo del proyecto.

2.1. El pipeline en tres fases

- **Fase I — Ingesta**. Se sube el estudio DICOM y el informe tecnico (PDF) a la carpeta del paciente en Idonia (PATIENT/{dni}/{study_id}).
- **Fase II — Humanizacion y validacion**. Recog transforma el informe tecnico; el cinturon lo evalua en cuatro capas y emite un veredicto (APPROVE / REVIEW / REJECT). Solo si supera el gate se reinyecta el informe humanizado en Idonia.
- **Fase III — Entrega**. Se genera un Magic Link (URL + PIN) para que paciente y medico accedan al material aprobado.

3. Arquitectura de la solucion

El sistema está organizado por capas con responsabilidades estrictas y dependencias inyectadas, de modo que la lógica de negocio nunca conoce el detalle de transporte de las APIs.

Modulo	Responsabilidad
domain/	Modelos Pydantic inmutables (Patient, StudyRef, MagicLink, SafetyVerdict...). Son la moneda común del pipeline.
clients/	Adaptadores a Idonia y Recog. Cada uno con una implementación stub (offline) y otra live (API real) que cumplen el mismo protocolo.
evaluation/	El cinturón cuantitativo: las cuatro capas de evaluación, independientes y testeables por separado.
orchestration/	safety_belt (combina las capas y vota) y use_cases (las tres fases del pipeline).
api/	Servidor FastAPI: POST /ingest, /humanize, /deliver.
tests/ + run_demo	Suite pytest sin red (32 pruebas) y demo E2E ejecutable sin credenciales.

3.1. Decisiones de diseño y su porque

- **Cientes stub / live intercambiables.** Ambos cumplen el mismo protocolo (`clients/base.py`) y se inyectan por constructor. Pasar del demo offline a las APIs reales es una línea en `api/main.py`, con cero cambios en la lógica de negocio. Esto permite demostrar el sistema completo sin depender de la disponibilidad de terceros.
- **Modelos inmutables (Pydantic frozen).** Una vez Idonia devuelve un `StudyRef`, nadie puede mutarlo. Facilita razonar sobre el estado del pipeline y es la base de un audit trail limpio (el demo imprime la traza completa de llamadas a Idonia).
- **Cinturón de doble backend.** Cada capa semántica tiene un backend léxico (sin descargas, corre en cualquier sitio) y uno avanzado (modelos transformer o LLM). El léxico es el default del demo; el avanzado es el de producción. El intercambio es, de nuevo, una línea.

4. El cinturón cuantitativo de fidelidad clínica

Es la pieza central. Evalúa el informe humanizado contra el original en cuatro capas complementarias y emite un veredicto por votación. Cada capa responde a una pregunta clínica distinta:

Capa	Pregunta	Implementación
0 — Legibilidad	¿El paciente lo entiende? (INFLESZ ≥ 55)	<code>readability.py</code>
1 — Checklist	¿Están los hallazgos, sin atenuar la gravedad?	<code>clinical_checklist.py</code>
2 — NER recall	¿Se preservan las entidades clínicas?	<code>clinical_ner.py</code>
3 — Fidelidad	¿El humanizado no afirma nada falso?	<code>clinical_nli.py</code> / <code>clinical_llm_judge.py</code>

La **política de voto** traduce los votos de las capas que votan en una decisión accionable:

Votos a favor	Decision	Acción sobre el informe humanizado
3 / 3	APPROVE	Reinyectar en Idonia.
2 / 3	REVIEW	Reinyectar con marca de revisión.
≤ 1 / 3	REJECT	NO reinyectar — protección del paciente.

La Capa 3 admite tres modos según el backend inyectado, sin cambiar la interfaz: **entailment léxico** (default offline), **contradicción semántica** (mDeBERTa) y **LLM-as-a-Judge** (Gemini), siendo este último el de mayor precisión. La separación de responsabilidades es deliberada: la cobertura («no se

omite ningún hallazgo») la garantizan las capas 1 y 2; la Capa 3 mide lo complementario («lo que se dice no es falso»). No son redundantes.

5. Dificultades técnicas y como se resolvieron

5.1. Autenticación heterogénea de las dos APIs

Las dos APIs autentican de forma completamente distinta y ninguna ofrece un login estándar. **Recog** usa una API key simple en cabecera X-API-Key (formato `rrk_...`). **Idonia** exige un **JWT autofirmado**: el cliente firma un token HS256 con la *api_key* en el claim y el *api_secret* (con prefijo S2, decodificado en base64url) como clave de firma. Resolverlo exigio leer el Swagger de staging y reproducir el esquema de firma exacto; quedo encapsulado en el cliente live de Idonia.

5.2. La calidad de Recog depende de recibir el informe integro

Al validar contra producción descubrimos que enviar a Recog un fragmento o un resumen previo del informe degrada directamente la salida: con un recorte centrado en el LCA, Recog omitió los otros cinco hallazgos. Con el informe completo (3.541 caracteres) preservó los seis hallazgos principales. La conclusión se codificó como restricción del pipeline: `HumanizeReport` recibe el texto original sin truncar; cualquier preprocesado que recorte texto antes de Recog está prohibido por diseño.

5.3. El propio validador penalizaba informes correctos

El hallazgo metodológicamente más valioso: el cinturón *lexico* marcaba como fallido un informe humanizado que era clínicamente fiel. La causa era doble, y distinguir ambos tipos fue clave para no perder el tiempo:

- **Falsos positivos de patrón mal calibrado** (bugs del regex, corregibles a mano). Ejemplo: el patrón de atenuación del LCM se disparaba con «...sin rotura completa», que es una negación fiel. Se añadió un *negative lookbehind* para que la atenuación solo salte cuando la lesión se describe como más grave de lo que es.
- **Límites semánticos inherentes al matching lexico** (no son bugs). Comparar cadenas nunca reconocerá que «lesión por golpe en los huesos» equivale a «edema óseo en patrón pivot-shift». Esto no se arregla con más regex: se delega al backend semántico.

Este caso real es la justificación empírica de la arquitectura de doble backend: no es un fallo, es la demostración de que el diseño anticipaba correctamente la limitación.

5.4. NER no es lo mismo que normalización de conceptos

Al activar el NER transformer esperábamos que resolviera el problema de sinónimos, pero el recall cayó (de 56% a 8,6%): el NER extrae spans literales del documento que rara vez coinciden con la redacción del informe humanizado. El humilde lexicon hecho a mano resultó ser, de facto, una capa de **normalización** a conceptos canónicos que el NER no aporta. La lección —que el problema real es de *entity linking* (SNOMED-CT / UMLS), no de reconocimiento— nos llevó a una solución pragmática: un diccionario curado técnico↔laico que elevó el recall de 56% a 64% con coste de implementación cero.

5.5. Truncación silenciosa del juez LLM por tokens de razonamiento

Al integrar el juez LLM (Gemini 2.5 Flash), su respuesta llegaba truncada tras el primer hallazgo: el modelo consumía su presupuesto de tokens en razonamiento interno antes de emitir el JSON, dejando ~68 tokens para la respuesta real. El fix fue desactivar ese razonamiento (`thinking_budget=0`) y ampliar `max_output_tokens` a 8192, además de forzar `response_mime_type=application/json` y extraer el array con delimitadores robustos.

5.6. Portabilidad de la salida en consola

El resumen del cinturón usa glifos de estado (validado / revisión / rechazado) para comunicar el veredicto de un vistazo. En consolas cuyo codepage por defecto no es UTF-8 (Windows cp1252) esto abortaba el demo. Se forzó la salida a UTF-8 en el punto de entrada, garantizando que el demo corra en cualquier máquina del jurado.

6. Validación experimental con datos reales

El desarrollo se llevó como una bitácora de experimentos (ocho entradas fechadas) sobre un caso clínico ficticio pero realista: paciente J.L.G.M., 35 años, RM de rodilla 1.5T, caída en Picos de Europa con mecanismo pivot-shift y siete hallazgos verificables (rotura completa del LCA, rotura grado III del menisco interno, edema óseo en patrón pivot-shift, distensión grado I del LCM, condromalacia grado II, derrame articular moderado y recomendación de valoración por traumatología).

6.1. Cinturón en modo léxico (default offline)

Se evaluaron tres informes: el real de Recog, un «gold» humanizado de referencia y un «adversarial» con atenuaciones sembradas a propósito.

Informe	Decision	Capa 1	NER recall	NLI léxico	INFLESZ
Recog real	REJECT	No	64,0 %	28,6 %	65,3
Gold	REVIEW	Si	80,0 %	38,1 %	62,5
Adversarial	REJECT	No	48,0 %	36,4 %	57,9

Lectura honesta: con el backend léxico ningún informe alcanza APPROVE. El gold se queda en REVIEW (la política 2/3 aun lo reinyecta) por falsos positivos conocidos de la Capa 3 léxica, que penaliza parafrasis correctas. El adversarial se bloquea por la Capa 1 (atenuaciones de gravedad).

Que el modo barato no apruebe ni siquiera al mejor informe fiel no es un bug que escondamos: es la motivación medida de las capas semánticas.

6.2. Cinturón en modo LLM-as-a-Judge (Gemini 2.5 Flash)

El juez LLM evalúa cada hallazgo de forma atómica con cinco categorías (preserved / simplified / omitted / attenuated / hallucinated) e instrucción explícita de fundamentación para no rellenar omisiones con conocimiento médico propio. La distinción simplified vs attenuated elimina los falsos positivos del modo léxico sin perder ningún ataque real:

Informe	Preserv.	Simplif.	Omit.	Atenu.	Decision
Recog real	2	5	0	0	PASS
Gold	3	4	0	0	PASS
Adversarial	2	1	1	3	FAIL

El juez detecta con confianza 1.0 los cuatro ataques del adversarial (rotura del LCA presentada como «estirada», rotura del menisco como «fisura que se cura sola», omisión de la condromalacia y sustitución de la derivación a traumatología por fisioterapia conservadora) sin producir un solo falso positivo sobre los informes válidos. Coste por evaluación completa: una llamada API, 2–3 s de latencia.

7. Justificación biomédica y rigor científico

Cada decisión de diseño se apoya en literatura y en el marco normativo:

- **Legibilidad (Capa 0).** Índice INFLESZ / Szigriszt-Pazos, estándar de legibilidad en español, con umbral adaptado al ámbito sanitario.

- **Severidad opcional (Capa 1).** La Ley 41/2002 de Autonomía del Paciente exige información «comprensible y adecuada»; Devaraj et al. (2022) muestran que la comprensibilidad no requiere nomenclatura radiológica verbatim. Por eso el checklist exige *presencia* de todos los hallazgos, pero solo exige *gravedad literal* donde la gradación es clínicamente decisiva (LCA completa/parcial, derivación a cirugía).
- **Diccionario técnico↔laico (Capa 2).** Enfoque documentado en Devaraj et al. (2022) para cubrir la brecha clínico-coloquial sin entity linking completo.
- **LLM-as-a-Judge (Capa 3).** Paradigma de Zheng et al. (2023, MT-Bench), con grounding explícito según Ramprasad & Wallace (NeurIPS 2025) y referencias específicas de evaluación factual de informes de imagen: RadFact (Bannur et al., 2023) y GREEN (Ostmeier et al., 2024).

8. Uso crítico de la IA

El proyecto no usa la IA como oráculo, sino con conciencia de sus límites. El mejor argumento de uso crítico es que **detectamos y documentamos las limitaciones de nuestro propio validador**: medimos que el cinturón léxico fallaba sobre informes correctos, diagnosticamos por qué fallaba en cada capa, distinguimos falsos positivos corregibles de límites semánticos de fondo, y aplicamos a cada uno la solución adecuada. Cuando la hipótesis previa («los modelos semánticos lo arreglan») no se confirmó del todo, lo registramos en vez de maquillarlo. La arquitectura final —cinturón léxico de coste cero para cobertura, más juez LLM para fidelidad semántica— es el resultado de esa honestidad metodológica, no de un eslogan.

9. Herramientas de IA empleadas como apoyo al desarrollo

Conviene distinguir dos planos. **La IA del producto** —la NLP de Recog, los modelos de NER y NLI, y el juez LLM basado en Gemini— es el objeto del reto y está descrita en las secciones anteriores. Aparte, durante el desarrollo nos apoyamos en herramientas de IA generativa, de forma supervisada y crítica:

- **Claude (Anthropic).** Asistente de programación empleado para acelerar la implementación (estructura del paquete, clientes, suite de pruebas), para el cruce sistemático de los números documentados contra la salida real de los scripts, y como apoyo en la redacción técnica. Todo el código y los resultados se revisaron y verificaron ejecutando las pruebas y el demo.
- **NotebookLM (Google).** Empleado para sintetizar y consultar la documentación de las APIs y la literatura científica de referencia (legibilidad, LLM-as-a-judge, evaluación factual de informes de imagen), facilitando la fundamentación biomédica de las decisiones de diseño.

El uso de estas herramientas fue siempre de *apoyo*: las decisiones de arquitectura, la calibración de umbrales y la validación experimental son fruto del juicio del equipo, contrastado con datos reales y con literatura.

10. Estado de implementación y trabajo futuro

Operativo y verificado: el cinturón completo (cuatro capas), el pipeline en modo stub, el demo E2E, la suite de 32 pruebas, la API FastAPI con manejo de errores HTTP, el juez LLM (Gemini) y la humanización de Recog contra producción.

Pendiente / trabajo futuro:

- Validación end-to-end del modo live de Idonia (JWT y Magic Link contra staging), dependiente de la activación por parte de su equipo de soporte.

- *Entity linking* completo (ClinLinker-ES sobre SNOMED-CT) para resolver sinonimos de forma sistemática y sustituir el diccionario curado.
- Reformulación de la métrica de la Capa 2 hacia solapamiento semántico, y filtro de frases definitorias en el detector de contradicciones.

El núcleo del sistema —el cinturón cuantitativo y el pipeline— está listo, probado y documentado. Su valor no es solo conectar Idonia y Recog, sino interponer entre ambos un criterio de seguridad clínica medible y honesto sobre sus propios límites.